



ZCBS Documentatie

Bijlage J:

Handleiding PDF-2-ZCBS

**ZCBS-hulpprogramma
om**

**PDF's te splitsen
en/of om te zetten in**

**ZCBS-OCR-tekstbestanden
en
thumbnail images**

Gerard J.H. van Nes

versie 1.16

25-01-2022

Vorige versie : 1.0 (03-03-2021)

1.1 (15-04-2021)

1.15 (07-08-2021)

Huidige versie : 1.16 (25-01-2022)

De huidige versie (1.16) van dit document bevat t.o.v. de eerdere versie (1.15) onder meer:

- uitbreiding hoofdstuk 'Automatische verwerking via de .ini file'
- nieuw hoofdstuk 'CONFIG instellingen'
- nieuw hoofdstuk m.b.t. PDF24
- diverse tekstuele aanpassingen en kleine uitbreidingen

Vervanging splittxt.exe:

Dit hulpprogramma vervangt in principe geheel het ZCBS-hulpprogramma `splittxt.exe` (bijlage G).

Het oorspronkelijke programma `splittxt.exe` is in zijn geheel opgenomen in dit uitgebreidere programma `pdf2zcbs.exe`.

Toepassing:

Dit programma kan uitstekend gebruik worden bij beeldbanken voor *onder meer* tijdschriften, kranten, krantenknipsels, advertenties, documenten, memo's, recepten, brieven, boeken, etc..

Locatie van dit document:

- ZCBS-documentenbank (F4):

- [Wat is nieuw in ZCBS, v4.13 van voorjaar 2022](#) NIEUW
- [Handleiding A: backup.exe](#)
- [Handleiding B: images.exe](#)
- [Handleiding C: zoekvervang.exe](#)
- [Handleiding D: ZCBS-slideshows](#)
- [Handleiding E: Stappenplan](#)
- [Handleiding F: ZCBS vanaf een USB-stick](#)
- [Handleiding G: splittxt.exe](#)
- [Handleiding H: exif.exe](#)
- [Handleiding I: INSERT](#) UPDATE
- [Handleiding J: pdf2zcbs.exe](#) UPDATE
- [Documenten van leden: Handleiding Forum ZCBS \(2018\)](#)
- [Documenten van leden: Foto's van informatie voorzien \(personen nummers\) via Greenshot \(2017\)](#)

Documentnummer	: 050
Titel	: Handleiding J: pdf2zcbs.exe
Auteur(s)	: Nes, G.J.H. van (Gerard)
Datum laatste versie	: 07-08-2021 (Opm.: diverse aanpassingen t.o.v. versie 1.0 (van 03-03-2021) en versie 1.1 (van 15-04-2021))
Bijzonderheden	Met het Windows ZCBS-hulpprogramma <code>pdf2zcbs.exe</code> kan men: 1. een PDF splitsen in meerdere losse PDF's (<i>het 1e deel van het programma</i>), 2. een map met PDF's automatisch omzetten (<i>het 2e deel van het programma</i>) naar: a. map met de OCR-teksten (één tekstregel per record) b. map met de small-images (thumbnails eerste pagina betreffende PDF) Dit hulpprogramma vervangt in principe geheel het ZCBS-hulpprogramma <code>splittxt.exe</code> (bijlage G). Het oorspronkelijke programma <code>splittxt.exe</code> is in zijn geheel opgenomen in dit uitgebreidere programma <code>pdf2zcbs.exe</code>. Zie ook de instructie video's op: www.zcbs.nl/cgi-bin/videodocs.pl?s=pdf2zcbs&d=gallery Zie ook de webinar presentatie op: www.zcbs.nl/cgi-bin/documentatie.pl?i=164
Type document	: C. ZCBS-tools (Bijlage)
Aantal pagina's	: 14
Download link	: www.zcbs.nl/documentatie/pdf/050.pdf (de documentatie) www.zcbs.nl/downloads/pdf2zcbs.zip (het programma)




Gerard J.H. van Nes
De Dars 9
1751 PD Schagerbrug
0224 57 1918
065 085 1314
vannes@zcbs.nl
www.zcbs.nl
www.zbbs.nl

Inhoudsopgave

1.	Algemeen	5
2.	Beschikbaarheid en installatie van het programma	5
3.	Demonstratie van het programma	6
4.	Omzetten OCR-tekst uit de PDF naar één-regelige zinnen	8
5.	Probleem-1: PDF bevat geen OCR.....	9
6.	PDF24	9
7.	Probleem-2: PDF is niet te splitsen of paginanummers niet herkend.....	10
8.	Automatische verwerking via de .ini file	11
9.	Upload bestanden naar de webserver	15
10.	CONFIG instellingen	15
11.	Verdere opmerkingen.....	16
12.	Tot slot.....	17


Klik op videodocument voor vergroting en meer informatie



Video: Van leestafel naar beeldscherm
- pdf2zcbz deel 1



Video: Van leestafel naar beeldscherm
- pdf2zcbz deel 2



Video: Van leestafel naar beeldscherm
- pdf2zcbz deel 3



Video: Van leestafel naar beeldscherm
- pdf2zcbz deel 4



Video: Van leestafel naar beeldscherm
- pdf2zcbz deel 5



Video: PDF24 - Toolbox

[Lijst weergave](#)

Zie ook de video-instructies op: www.zcbs.nl/cgi-bin/videodocs.pl?s=pdf2zcbz&d=gallery

Documenten- en tijdschriften (beeld)banken

met
doorzoekbare PDF's



GERARD van Nes

webinar ZCBS 15 april 2021

Zie ook de webinar-presentatie op: www.zcbs.nl/documentatie/pdf/164.pdf

1. Algemeen

Met het Windows ZCBS-hulpprogramma `pdf2zcbs.exe` kan men:

1. een PDF splitsen in meerdere losse (artikelen/pagina's) PDF's (*het 1e deel van het programma*),
en/of
2. een map met PDF's automatisch t.b.v. een ZCBS-beeldbank omzetten (*het 2e deel van het programma*)
naar:
 - a. een map met de OCR-teksten (één tekstregel per record)
 - b. een map met de small-images (thumbnails; eerste pagina van de betreffende PDF)

Dit hulpprogramma vervangt in principe geheel het ZCBS-hulpprogramma `splittxt.exe` (ZCBS-bijlage G). Het oorspronkelijke programma `splittxt.exe` is in zijn geheel opgenomen in dit uitgebreidere programma `pdf2zcbs.exe`.

2. Beschikbaarheid en installatie van het programma

Het programma kan gedownload worden via de knop  op de ZCBS homepage en vervolgens onderaan de getoonde webpagina de link: *Download ZCBS-hulpprogramma pdf2zcbs.exe*.

Beschikbare interne/systeem ZCBS-programma's:


- [Download ZCBS backup programma backup.exe](#) (MS-Windows .zip/.exe file; versie 3.0 van 06-04-2020/18-02-2021)
- [Download image-conversie/upload programma images.exe](#) (MS-Windows .zip/.exe file; versie 3.25 van 14-08-2019/18-02-2021)
- [Download database-mutatie programma zoekvervang.exe](#) (MS-Windows .zip/.exe file; versie 1.3 van 25-02-2015)
- [Download OCR-hulpprogramma splittxt.exe](#) (MS-Windows .zip/.exe file; versie 2.1 van 20-06-2015)
- [Download OCR-hulpprogramma pdf2zcbs.exe](#) (MS-Windows .zip/.exe file; versie 1.6 van 07-11-2021)

Daarnaast kan het programma ook gedownload worden via de ZCBS-documentenbank (document nr. 50).

Installatie van de bestanden:

1. Zorg voor een lege (werk)map op uw PC (of externe harde schijf), waarin u met `pdf2exe.exe` wilt werken, bijvoorbeeld een map met de naam: `d:\zcbs\pdf2zcbs\`
2. Unzip het gedownloade programma waarbij de volgende bestanden worden geplaatst:
 - `pdf2zcbs.exe` : het gecompileerde Perl programmaen de 3 mappen:
 - `bin` (deze bevat 3 hulpprogramma's welke door `pdf2zcbs.exe` wordt gebruikt)
 - `doc` (deze map bevat onder meer de handleiding `manual-pdf2zcbs.pdf`)

Bij de verwerking wordt door `pdf2zcbs.exe` de submap `output` aangemaakt met daarin submappen van alle nieuwe aangemaakte bestanden.



Name	Ext	Size	Date	Attr
[.]		<DIR>	23-01-2022 20:21	—
[bin]		<DIR>	08-02-2021 16:46	—
[doc]		<DIR>	02-03-2021 13:44	—
pdf2zcbs	exe	1.506.925	08-11-2021 00:28	a—

Hierboven de bestanden in de werkmap na installatie (getoond in Total Commander).

Let op:

De PDF's die via `pdf2zcbs` verwerkt worden moeten:

- a. Reeds OCR-tekst in zich hebben
- b. Bestandsnamen hebben die bestaan uit alleen: *kleine letters*, *cijfers*, en/of de tekens `-` en `_`



3. Demonstratie van het programma

Het programma voert 2 taken uit, *afhankelijk in welke map de PDF is geplaatst*:

1. plaats *een enkele* PDF welke gesplitst moet worden (en daarna eventueel verder verwerkt moet worden) *in dezelfde map* als waarin het programma pdf2zcbcs.exe is geplaatst
of
2. plaats één of meerdere PDF's *in dezelfde map* als waarin het programma pdf2zcbcs.exe is geplaatst

Afhankelijk of er *één of meerdere PDF's* zijn geplaatst zullen de vragen die het programma stelt een weinig verschillen.

0. **Start het programma pdf2zcbcs.exe door er (dubbel) op te klikken.** ¹

Het programma wordt opgestart in een DOS-box.

Eerst wordt enige informatie getoond inclusief de versie van het programma.

```
d:\zcbcs\pdf2zcbcs>pdf2zcbcs

-----
pdf2zcbcs: versie 1.16 (17-11-2021)      Info: Gerard van Nes (vannes@zcbcs.nl)
-----

Dit ZCBS-hulpprogramma zorgt voor het automatisch:
1. splitsen van een PDF in meerdere losse PDF's (het 1e deel van het programma),
2. omzetten van een map met PDF-documenten (het 2e deel van het programma)
   naar:
   a. een map met de OCR-teksten (een enkele tekstregel per record)
   b. een map met de small-images (en een map met large-images)
3. indien pdf2zcvbs.ini aanwezig is : aanmaak lege database updates.txt
-----
```

1. - Als er *geen PDF* wordt gevonden in de map waaruit pdf2zcbcs.exe wordt gestart, zal het programma eindigen.
- Als er *één enkele PDF* wordt gevonden **in dezelfde map** als die waarin het programma pdf2zcbcs.exe staat, wordt gevraagd of deze gesplitst moet worden. ²
- Als er *meerdere PDF's* zijn geplaatst **in dezelfde map** als die waarin het programma pdf2zcbcs.exe staat, worden onderstaande vragen *niet* gesteld en worden de PDF's automatisch verplaatst naar de map /pdf waarna meteen het 2^e gedeelte van het programma wordt gestart.

```
-----
Aanwezige PDF in de huidige map:
- 2021010024.pdf
-----

> Deze PDF splitsen in (groepen van) losse pagina's (default = N)?
j

> Naam output PDF's (prefix) minus de paginanummers? (bijvoorbeeld abc202103....)
202101

> Aantal loze pagina's aan het begin van de PDF? (default= 0)
2

> In welke pagina's? (bijvoorbeeld: 3 4 5-10 11-15 15-17 18)
2 3-11 12-17 18-21 22-23 24

== Aangemaakt in map output/pdf: 2021010202.pdf
== Aangemaakt in map output/pdf: 2021010311.pdf
== Aangemaakt in map output/pdf: 2021011217.pdf
== Aangemaakt in map output/pdf: 2021011821.pdf
== Aangemaakt in map output/pdf: 2021012223.pdf
== Aangemaakt in map output/pdf: 2021012424.pdf
-----
```

De aangemaakte (gesplitste) PDF-artikelen worden geplaatst in de map: output/pdf.


Als deze map nog niet bestaat wordt deze door het programma aangemaakt.

¹ Men kan ook vanuit de map waarin pdf2zcbcs.exe staat, via het commando cmd een DOS-box openen.

² Natuurlijk kan splitsing van een PDF alleen plaatsvinden als er slechts één PDF aanwezig is!

Door dit gedeelte van het programma worden er dus 3 vragen gesteld:

- i. Het gemeenschappelijke deel van de naam van de output files (van i.h.a. de te splitsen PDF-artikelen).
Aan deze naam wordt door het programma de begin- en eindpagina's toegevoegd.
- ii. Het aantal 'loze' pagina's aan het begin van de te splitsen PDF.
Veelal heeft het titelblad en de volgende pagina('s) geen pagina nummer en begint het eerste artikel (met pagina nummer 1) pas op de 3^e pagina van het PDF-bestand. Feitelijk moet dus opgegeven worden het verschil tussen de *PDF pagina nummering* en het *pagina nummer van de bladzijde zelf*.



- iii. De begin- en eind pagina's (van het oorspronkelijke document) van de te splitsen artikelen.
Feitelijk zijn dat de bladzijde nummers onderaan van het betreffende PDF-artikel.
Bij *een enkele* pagina is een enkel paginanummer voldoende (zie ook het voorbeeld).

2. In het 2^e gedeelte van het programma kunnen PDF's verwerkt worden naar ZCBS .txt en .jpg bestanden.

In dit gedeelte wordt *van elke PDF* in de map /pdf :

- a. De OCR-tekst geëxtraheerd en deze omgezet in één zin per regel output.
Van elk geconverteerde bestand wordt daarbij het gevonden aantal zinnen getoond.
- b. De eerste pagina van elke PDF omgezet in een .jpg bestand van max. 250x250 pixels t.b.v. de ZCBS-webservermap /small .

```
-----
> PDF's in map output/pdf verwerken naar txt + jpg's? (default = J)
j
-----
Aantal aanwezig PDF's in de map /pdf: 6

> Betreft het (presentatie) slides? (default= N)
n

Verwerking: 2021010202.pdf : bevat 40 zinnen (lengte > 300: 0x) --> output/ocr/2021010202.txt
Verwerking: 2021010202.pdf : bevat 30 zinnen (lengte > 300: 0x) --> output/ocr/2021010202.txt
Verwerking: 2021010311.pdf : bevat 290 zinnen (lengte > 300: 1x) --> output/ocr/2021010311.txt
Verwerking: 2021011217.pdf : bevat 145 zinnen (lengte > 300: 6x) --> output/ocr/2021011217.txt
Verwerking: 2021011821.pdf : bevat 57 zinnen (lengte > 300: 4x) --> output/ocr/2021011821.txt
Verwerking: 2021012223.pdf : bevat 40 zinnen (lengte > 300: 2x) --> output/ocr/2021012223.txt
Verwerking: 2021012424.pdf : bevat 11 zinnen (lengte > 300: 1x) --> output/ocr/2021012424.txt

Tevens de thumbnails van de 1e pagina van de PDF's aangemaakt --> output/small/*.jpg

-----
That's all folks
Type return to exit
```

In dit gedeelte van het programma wordt er nog één vraag gesteld:

- i. Of het (presentatie) slides betreffen of een 'normaal' document.
Bij (presentatie) slides worden zinnen i.h.a. niet afgesloten met een punt waardoor het programma niet kan herkennen wat een zin is. Dit i.t.t. een 'normaal' document.
Ook bijvoorbeeld advertenties, familieberichten of een index pagina's kennen veelal geen punten om een einde van een zin aan te geven.

Men ziet dat bij deze tijdschriftartikelen er ook zinnen tussen zitten *met meer dan 300 tekens*. In een aantal gevallen ligt dat nog aan een fout in het programma. Soms is er geen punt als einde zin aanwezig.
Het kan echter ook liggen aan teksten in (ge-OCRde) afbeeldingen, tabellen, overzichten, etc..

Bij elke run van het programma wordt er ook een log-file (output/log/log-datum-tijd.txt) aangemaakt.

4. Omzetten OCR-tekst uit de PDF naar één-regelige zinnen

Met het Windows ZCBS-hulpprogramma pdf2zcbcs.exe kan men de tekst die uit het OCR-programma komt, *splitsen in losse zinnen*. Dat is gebaseerd het feit dat een zin begin met een hoofdletter en eindigt met een punt. Met speciale gevallen als afkortingen (Mevr.) en namen (A.B. Janssens) wordt zoveel mogelijk rekening gehouden.

De reden dat de (ruwe) OCR-tekst t.b.v. ZCBS in losse zinnen wordt gesplitst, is dat bij het zoekresultaat van een ZCBS-beeldbank de i.h.a. *gehele zinnen getoond kunnen worden* waarin een opgegeven zoekwoord voorkomt, zonder dat het hele document getoond hoeft te worden.

10.



Artikelnummer: 2019031117 **Geplaatst op internet: 10-11-2019**

Boerderij Leeuwenhorn
ZHB 2019-03; auteur: Boots, J. (Jacob)

Voor de definitieve bedijking van de Zijpe in 1597 lagen er in dit uitgestrekte waddengebied een aantal kwelders, die alleen bij een hoge vloed nog overstromden. Een van deze "eilanden" was genaamd Groot Keyns. Deze was dusdanig van oppervlakte dat daer achttien coyen pleghen up te gaen weyden. De Grote Keins is nog steeds herkenbaar in het polderlandschap van de Zijpe door een afwijkende verkaveling. In sommige geschriften wordt dit voormalige eilandje "Groot Keyns of Leeuwenhorn" genoemd. De toevoeging Leeuwenhorn zou voortkomen uit de 7e eeuw toen koning Idsaert I van Friesland de bijnaam verwierf "Idsaert met het rode leeuwenhoofd".

- Als we langs de oostzijde van de Grote Sloot tussen **Schagerbrug** en Keinsmerbrug rijden zien we meteen voorbij poldermolen D een boerderij met de naam Leeuwenhorn.
- Er werd geen moment gearzeld en spoorwagens vertrokken vader Jacob en zoon Gerrit met paard en rijtuig richting **Schagerbrug**.
- Zij was Aagje Bruijn, dochter van een beurtschipper uit **Schagerbrug**.
- Er wordt een woning gekocht aan de Grote Sloot nabij **Schagerbrug** met een fink stuk tuin.

In dit voorbeeld is gezocht in de (tijdschriften)beeldbank met het zoekwoord Schagerbrug.
Het artikel bevat 4 zinnen waarin het betreffende woord voorkomt.

Als voorbeeld hieronder een door een OCR-programma gegenereerde tekst van een gescanned document:

SELFMADE ZAKENMAN
Huib Kooij
Op de tentoonstelling 'Speelgoed uit de oude doos' die tot april 2012 in het museum van Harenkarspel te bewonderen viel, stond ook een speelgoedwinkelkje. De inhoud daarvan was grotendeels zoekgeraakt, maar Miep Buter maakte ons erop attent dat het een stoffenwinkelkje voorstelde, ooit geschonken door Huib Kooij, voormalig confectionair in Schagen. Er hoort een levensverhaal bij dat Huib in 1983 zelf schreef. Aan de hand van dit verhaal wordt dit winkelkje ineens wel heel bijzonder.

Op 10 april 1915 ben ik als boerenzoon geboren aan de Stolpen (gemeente Zijpe), in de boerderij 'Op Hoop van Zegen.' Mijn vader was naast boer ook veehandelaar. Toen ik 8 jaar oud was, moest mijn moeder vanwege haar gezondheid en op doktersadvies uit de boerderij. We verhuisden daarom in 1923 naar 't Zand, waar mijn vader een klein wit huisje kocht van Arie Tuin aan het Molenpad. Daar vader tot zijn 25e jaar timmerman was geweest, bouwde hij er zelf een grote schuur en koeboet achter. Toen ik tien jaar oud was, begonnen mijn ouders na te denken over wat ik later zou moeten worden. Omdat ik niet sterk en veel ziek was, besloten ze mij in de muziek te laten leren. Voor boer was ik niet in de wieg gelegd en voor veehandelaar evenmin. In tegenstelling tot mijn broer, die vijf jaar ouder was en op 13-jarige leeftijd na schooltijd al de boer opging om dooie lammeren en kippen te kopen. Hij is dan ook zijn hele leven boer en veehandelaar gebleven.

Vast besluit
Zo gezegd, zo gedaan. Er kwam een piano in huis en gedurende twee jaar fietste ik elke week naar Schagen, waar ik pianoles kreeg van mijnheer Sprengers die boven de hoedenzaak van de dames Hedde en Lips woonde. Later ben ik nog zes jaar pianist geweest in het Zijper

Als deze tekst wordt ingevoerd in het programma pdf2zcbcs.exe worden de zinnen op aparte regels geplaatst:

SELFMADE ZAKENMAN
Huib Kooij Op de tentoonstelling 'Speelgoed uit de oude doos' die tot april 2012 in het museum van Ha De inhoud daarvan was grotendeels zoekgeraakt, maar Miep Buter maakte ons erop attent dat het een stc Er hoort een levensverhaal bij dat Huib in 1983 zelf schreef.

Aan de hand van dit verhaal wordt dit winkelkje ineens wel heel bijzonder.

Op 10 april 1915 ben ik als boerenzoon geboren aan de Stolpen (gemeente Zijpe), in de boerderij 'Op t Toen ik 8 jaar oud was, moest mijn moeder vanwege haar gezondheid en op doktersadvies uit de boerderi we verhuisden daarom in 1923 naar 't Zand, waar mijn vader een klein wit huisje kocht van Arie Tuin a Daar vader tot zijn 25e jaar timmerman was geweest, bouwde hij er zelf een grote schuur en koeboet ac Toen ik tien jaar oud was, begonnen mijn ouders na te denken over wat ik later zou moeten worden.

Omdat ik niet sterk en veel ziek was, besloten ze mij in de muziek te laten leren.

Voor boer was ik niet in de wieg gelegd en voor veehandelaar evenmin.

In tegenstelling tot mijn broer, die vijf jaar ouder was en op 13-jarige leeftijd na schooltijd al de Hij is dan ook zijn hele leven boer en veehandelaar gebleven.

vast besluit zo gezegd, zo gedaan.

Er kwam een piano in huis en gedurende twee jaar fietste ik elke week naar Schagen, waar ik pianoles Later ben ik nog zes jaar pianist geweest in het Zijper salonorkest onder leiding van Piet Kronenburg op 10-jarige leeftijd kwam er voor mij echter nóg een belangrijk moment in mijn leven.

In 't Zand was er namelijk een manufactureurwinkel van G. Zomerdijk, genaamd 'De kleine winkel,' die l Na een grote verbouwing heropende Zomerdijk zijn winkel die ondanks zijn veel grotere oppervlakte 'De Mijn moeder ging 's middags naar de opening en ik mocht mee.

Vanaf die dag stond voor mij het besluit vast: ik wilde manufacturier worden.

Speelgoedwinkelkje twee jaar later knutselde ik van een zeepkist die ik van winkelier van der Oord ha mijn eerste winkelkje wilde ik niet zoals Zomerdijk 'De kleine winkel' noemen.

Ik veranderde de naam in 'Klein Begin.' weer een jaar later - ik was toen dertien - verliet ik de lag op aanraden van de manufacturier dhr.

Brouwer uit Callantsoog, die om de twee maanden bij mijn moeder met de poepzak kwam te venten, zou i Met behulp van Brouwer (want ik had zo van de schoolbanken af natuurlijk zelf nergens verstand van) k die werden opgeslagen in een grote linnenkast van moeder, die op zolder stond.

Eerste klant Op 1 juni 1928 begon ik mijn loopbaan als manufacturier (of lappiespoep, zoals dat in di om één uur 's middags vertrok ik per nieuwe fiets met voor en achter een grote bagagedrager richting mijn eerste klant zou vrouw Glas worden

Men ziet in dit voorbeeld dat elke zin bij het begin van een regel begint.

Echter een en ander is geheel afhankelijk van de:

- de kwaliteit van gescande documenten (scan altijd met een zwart vel onder het document!)
- het programma dat de tekst uit het document extraheert (in dit geval door de interne utility `pdftotext.exe`).

Controleer daarom altijd de aangemaakte tekst in de map: /ocr !!

5. Probleem-1: PDF bevat geen OCR

In principe bevat een PDF welke is aangemaakt *vanuit een documentverwerkingsprogramma*, altijd OCR.

Dit i.t.t. een document welke is gescand. Een gescand document dient dus met een apart programma van OCR-tekst te worden voorzien.

Een uitstekend (niet gratis) programma dat hiervoor gebruikt kan worden is bijvoorbeeld *ABBY FineReader*.

Ook (de betaalde versie van) *Adobe Acrobat* wordt door enkele ZCBS-instellingen (o.a. Museum Hoeksche Waard) voor deze taak gebruikt.

OCR-software welke verder door ZCBS-instellingen wordt gebruikt, onder meer:

- *SimpleSoftware*, online software (Oud-Castricum)
- *PDF-XChange* (Heemkundevereniging Berchs-Heem te Berghem)
- *READIRIS*, meegeleverd bij aanschaf printer (Historische Kring Berckhout Bobel Dijk)
- *PaperPort11 SE+*, meegeleverd bij aanschaf printer (Historische Commissie Terbregge's Belang)
- *PDF24* (in gebruik bij meerdere ZCBS-instellingen)

Daarnaast zijn er diverse andere, *al dan niet gratis*, programma's voor deze taak beschikbaar met wisselende kwaliteit en mogelijkheden,

Er zijn ook speciale (dure) scanapparaten die via firmware automatisch het document voorzien van OCR.

Afhankelijk van de kwaliteit van het gescande document *én* van de mogelijkheden van het OCR-programma, verkrijgt men een slecht/matig dan wel een zeer goede herkende tekstkwaliteit binnen de PDF.


Het is verstandig om, afhankelijk van het type document, altijd eerst even wat testjes uit te voeren.

6. PDF24

Het (gratis) programma PDF24 (<https://nl.pdf24.org>) verdient, *naast goede OCR-aanmaak mogelijkheden, bijzondere aandacht voor pdf2zcbz.exe gebruikers als 'probleemoplosser'* (zie latere hoofdstukken).

Downloadlink: <https://tools.pdf24.org/nl/creator>

Dit programma (*off-line versie*) kent uitgebreide functionaliteit op het gebied van PDF's.




Openingsscherm PDF24, versie 10.7.1

7. Probleem-2: PDF is niet te splitsen of paginanummers niet herkend

Er kunnen doorzoekbare PDF documenten zijn welke niet gesplitst kunnen worden in afzonderlijke delen/artikelen. Dat probleem is i.h.a. eenvoudig te verhelpen via het programma **PDF24**.

1. Start het (off-line) programma en kies de optie '*Bestandstools openen*' (onderaan de pagina):



2. Sleep het PDF bestand naar het PDF24 File Tools window links.
3. Kies: '*Pagina's uithalen*'. De PDF wordt nu ingelezen en de paginanummers worden getoond. Alle pagina's zijn reeds default geselecteerd.
4. Kies nu voor *opslaan* (pas eventueel opslaglocatie aan; er mogen voor pdf2zcb.exe geen haakjes of spaties in de PDF-bestandsnaam staan).

Kans is groot dat de PDF nu wel gesplitst kan worden met pdf2zcb.exe.
Zie ook de suggesties m.b.t. PDF24 in het hfdst 'Verdere opmerkingen'.

Via exact dezelfde manier kan de interne paginanummering van een aangeleverd PDF-bestand aangepast worden (zie in het volgende hoofdstuk de parameter PN (Pagina Nummers)).

Probeer altijd eerst bovengenoemde methode als een PDF-bestand bij de verwerking met pdf2zcb.exe problemen geeft m.b.t. bijvoorbeeld de paginanummering.

Dit geldt zeker voor PDF's die door derden zijn aangeleverd.

8. Automatische verwerking via de .ini file

In dezelfde map als waarin ook pdf2zcbs.exe staat, kan ook een bestand pdf2zcbs.ini worden opgenomen (zie voorbeeld hieronder).

Dit bestand kan:

1. reeds de antwoorden bevatten op de vragen die door pdf2zcbs.exe worden gesteld
en/of
2. reeds de invulling bevatten van velden van de bij de PDF's behorende ZCBS database-records.

Hieronder bijvoorbeeld het bestand dat wordt gebruikt bij het tijdschrift 'Zijper Historie Bladen' van de Historische Vereniging "De Zijpe" (www.dezijpe.nl/cgi-bin/zhb.pl).

Dit voorbeeld bestand is te vinden in de map /doc.

```
#####
#####
##
## pdf2zcbs.ini bestand
## 24-12-2021
## Tijdschrift: Zijper Historie Bladen
## Historische Vereniging "De Zijpe" (#12)
##
#####
SP Ja                                ## PDF Splitsen in losse pagina's?
OP 202104                            ## Output PDF [AANPASSEN]
LP 2                                 ## Loze Pagina's
PN 2 3 4-6 7-12 13-21 22-23         ## Pagina Nummers [AANPASSEN]
TJ Ja                                ## verwerken naar Txt en Jpg
PS Nee                               ## Presentatie Slide ?
#####
00 HVZ                               ## afk. instelling (zie config)
01 12                                ## inst. nummer

22 Tijdschrift                       ## veld-22
23 Historische Vereniging "De Zijpe" ## veld-23
10 Gepubliceerd                      ## veld-10
#####
#####
```

De regels na het # teken, zijn commentaarregels.

Het bestand pdf2zcbs.ini kan uit 3 delen bestaan:

1. **Antwoorden op de vragen (= sturing) van pdf2zcbs.exe**

In het *eerste gedeelte* (beginnend met SP, OP, etc) kunnen al vast de antwoorden gegeven worden op de vragen die het programma pdf2zcbs.exe stelt.

Missende antwoorden moeten tijdens de verwerking van pdf2zcbs.exe worden gegeven.

De parameters OP, LP, PN en PS.

OP: In dit voorbeeld wordt achter de opgegeven output PDF (OP 202101) nog de begin en eindpagina's opgenomen (elk 2 cijfers) hetgeen bijvoorbeeld als resultaat de bestandsnaam oplevert: 2021010311.txt

PN: Alleen het beginpaginanummer van het artikel wordt hier opgegeven dan wel de beginpagina, koppelstreepje, eindpagina. Er kunnen dus geen 2 gehele (korte artikelen op dezelfde pagina worden opgegeven.

LP: Een PDF-bestand *begint altijd te nummeren met pagina nummer 1.*

De eerste pagina van een tijdschrift kan beginnen met pagina 0, -1 of bijvoorbeeld 32 (bij het doornummeren van uitgaven).

LP = 1 minus 'het eerste paginanummer van de betreffende tijdschriftuitgave'.

Veelal is dat LP = 1-0 = 1, doch kan ook zijn: LP = 1-(-2) = 3 (voorkant, blanco achterkant en dan pagina 1) of bij het doornummeren van een uitgave: LP = 1-32 = -31

Veelal is het voor een bepaald tijdschrift *eenmaal uitproberen*.

PS: Bij bijvoorbeeld presentatie slides worden i.h.a. geen punten gebruikt om een zin of een tekststring te beeindigen. Het programma pdf2zcbs beschouwt dan bij de OCR-output aanmaak, elke regel als een gehele zin.

Let op:

Bij problemen met de parameter LP (opgegeven waarde klopt niet met de nummering), dan dient de PDF eerst via PDF24 behandeld te worden op de manier zoals beschreven in het vorige hoofdstuk (Bestandstools openen → Pagina's uithalen).



OCR -raw

Afhankelijk van de manier waarop de PDF is aangemaakt, kan de toevoeging van de regel:

OCR -raw

binnen het bestand pdf2zcbcs.ini soms een duidelijk veel beter tekstbestand aanmaken.

```
#####
SP Neen                                ## PDF splitsen in losse pagina's?
TJ Ja                                  ## verwerken naar Txt en Jpg
PS Nee                                 ## Presentatie Slide ?
#####
OCR -raw
#####
00 UuU                                  ## afk. instelling (zie config)
01 86                                  ## inst. nummer
#####
```

Deze toevoeging was bijvoorbeeld nodig bij de verwerking van de oude *Urker Couranten* van de Vereniging Vrienden van Urk (#86); zie: www.vriendenvanurk.nl/cgi-bin/documenten.pl



Het resultaat van de OCR-output, die door pdf2zcbcs.exe wordt aangemaakt *zonder* deze parameter en *met* deze parameter, is hieronder te zien:

```
#####
2 1 - 0 1 - 2 0 2 2 ( 1 7 : 0 2 ) ##### P D F 2 Z C B S ##### U E R S I E : 0 7 - 1 1 - 2 0 2 1 ##### N #####
oe iuile 2Fo NF1o.oI.2M.2Ge.ae sF eae.
ZATERDAG. 13 JA.NUARI 1912.
1e Jaargang.zyxwvutsr an 4 voor + het eiland URK.
Dit t bihalad vevreschcinijntt dEes FaZtaeterridaaegns. mmaaanadnednen 3535 cecnetst s bibj ij vovoorouriutibteteatalliingng. 404 0 ce
Eenkelelee nuuunmmemres 5 fi cecnetsts tetsUrUk.rk.
FbIfRrPbjrPriiJanrjncisGjoc.Gso.ppepSerpSerNerNorpDedopdrKsEiotesKiet z:yxwvBuB(UsUrrRqEpEaOaUanUdJmrVdeUlskrUaEjaisNhdJegnVdTwfEeTmoDn:d
_gghmgdhgdhdzohpvgvDLa-EstsgddvDtdvuvvgvbtDvovvgvbybuhdvgvuvvuyvgvgtbdsELvgagtveo-gbdvddedvnieeepioeohzdhpateantuaieaiggdhiioeroo
dageovdaceredablaeessgaggetvapztaoalseeaoot-goehtltbainejaoladaeezagedpavahlugeratemedhnteeoelstngedogeersnolridengkelalainoonnteteoede
ttaeaoozhmeivui-adllgaherotinoeunllededkhdovrea ngnlaodbovialakkhvdttireakveideovodkndvtoaeohhremw orRiezaeoidmsskeeadlmdtgeranemhiikwb
nahneliieaotdavidrosjitesueaillDoenlezvovaaaealodognriaeealaregvgvnoaejvadtMntNenseedlandaedeowiod-tgttvensitjolinmoiairDeeindadisralnwtteaan
fjmkintnlreglntmkgancionekotttclscngsln sbaaillria.leeagsey.nz.Rieanvuwcdnsneekmkrk n rofreedneuegattnVoluomad .ZJdrdtlnEHDAineOhgdgr ausJei
riass50ikisresldeeeuileetvanwew.nHsentsatotudarankkianrweouardeeieitebe.a.ehanaotwe.oildao1.eddaaettigtentitilllnVddstrntrgrtdngtnlrczalt
atjkaernurealsJewelzrstekevoreniofntre.eteoehgrsw lrtzshevlnrDevoesenteeteeteneoase.tedkndaderrsvd;nerkrriosr/ietsumleeeitrr neognoa:S7reSedmsn
drubdnlnlnrndcintkoesegsogovidaaeregtocinureietia0dkngodabedBrlrnsiemieejeinaeevumvovdgs0aaltegtweeltseemjelnanngeoeinneaneemdsrmeoaeilndodm
ntottvutinvurgne1weigesiaaikkorkutdntledcnrtndkkej onetwsweztgmoiesiticoVooovstgnadejud.o rVji nrejszeieFkg e7aal3Wtrata iuet 1joae7eakni t
coecperrlrmn"ebrddlehddeDvetjtjNEjrItteodtarvtuodahed(K"DrngsrerrmkveaerokerWitl mhdUONNtmslNizoddhrIvdA edocnl.aInDeeJogekehLANO"o.rWOEDzse
rirodheeooglloea0mnnelintmkirdeaeererciletgllddeBmtieraitgkenetvgteliluitnaeHbdoesiweereepvtlntcziidneaaedgttaemidaoea.rIjlrndieiseBknlleehtao
ujltinsjoeetnevsmeirug.s.n.oRtenthnggeinEoleeddsckeealevlndeseiieetookozdsejrdkumpesnrrehatuevtvgvltvngelgltojorensedheedsdezoentsnttaekboi
scsivscwrcngro oidiogn easuovhenedmvdvntseinllg.aonenletdtevlloaookeZlennenseoingnktrevorenegkntlr c;reshhee soenelenkdtteedreedeoaa(wi
a0eeteerikinaldedo.aionetgetvafnDeebethadelsostdet:lgeatgjdwmshorjeriikededdeeaoen0wk10laenkehebrleSerntdhogua0Deegaenaanerdkneertnls0eenltt
dlaBm.jovevudgesweeapaetidaenllwhneeffne1GieInpeaeoaeoiaetwiaeieeaztaeaaGeoteaut0au1"eaoGvajbeapliejjeenentrierdmrnatrhgwauoat"ineesnnn
1ltiott"uivatnsesoleeaaieNrIeueehdvreetoc"loe.dnerrsrtnegDeoeaa:.annmseeanneheerlbhenanesdafvdueljeeVneanrRvZtndrnreneoeie Uigadbeemhierrnt
lentncxe.anR MpnneeeNen.rainaTme r rRc.epugedeoteerleial.b.ehl.taewenrrthrtutPr.evldr.diuedsrLsi.en nrAeddnnoaeape.lidenrraPbriwkeede i nzt
t.J.eheze.ada.Dke0evollhtjeijeendm.utleninnredbnrbngtdornMetngnodoadnerunPrrninedenedznadnpndendcnpb-uetu/huvinnnnnvp nennunnetrvdkiteltrine
kzarcenmyvzlRrrrpnnaordenseIn.beemvBrieavroBk.ierrdidoavarlthvoaekrtjnewielogrejeuuletheotegeeuodkguaaikgegeotiuaeo.adesuenz7ddnloner
podnhzekeNeuShNwhwmineorececeoeerkerZrotseZdehripvsovoenisprieesenoeza-gGGeohpgeheinentnrisnes HHoeswoeieeiedadrsszenoe000ipnseseeein
edon heaiautitibain neceedezididrezenomumunneetivi icndbthng ciannkbbhbaeiunsci nseaud tandioerdnueeidenzeah zooniez llnneegauubutoneirco
#####
2 1 - 0 1 - 2 0 2 2 ( 1 7 : 1 6 ) ##### P D F 2 Z C B S ##### U E R S I E : 0 7 - 1 1 - 2 0 2 1 ##### N #####
No.. ZATERDAG. 13 JA.NUARI 1912.
1e Jaargang.zyxwvutsr Dit blad verschijnt des Zaterdag. /zyxwvutsrqponmlkjhgfedcbaZYXWUITS J\dres voor de Redactie en J\ministratie: .. BU
D.ii:COURANT TE.
URK.
Prijs per driezyxwvutsrqponmlkjhgfedcbaZYXWUITSRQPONMLKJHGFEDCBA ( maanden 35 cents bij vooruitbetaling. Franco per post 4 0 cents.
Enkele nummers fi cents bij G.. SNOEK. te Urk.
Prijs der advertenti n : van 1- 5 regels cents elke regel meer 3 cents. 3 maal plaatsing wordt slechts 2. maal .berekend. dverten n op abon
Dit NlllllIDr:r~~~~taat nit tu"olaa"n . Wie zich op dit blad niet wenscht te abonneeren .zende s.V.p. het V70igende nummer terug.
J\ministratie.
URKER.
COURI\NT. .De Loting.zyxwvutsrqponmlkjhgfedcbaZYXWUITSRQPONMLKJHGFEDCBA "Menigeen ziet met belangstelling en dikwijls ook met zekeren onrus
Door de verplichtingen van den dienst doch wordt er zoo vaak een ingrijpende verandering in het gezinsleven aangebracht.
Niet alleen hierdoor dat de zonen tijdelijk aan het huiselijk verkeer worden onttrokken och dat zijn onze visachers door de uitoefening van h
alles leeft van de visscherf en de opbrengst daarvan peantwoordt steeds minder aan de verwachtingen.
En daarbij komt nog de groote last van den zoogenaamden nasleep van den Dienst in het veelvuldig opkomen in-: spectie maken en de indeeling b
Ons zeevarend volkje dat aanmonstert op den logger of zich verhuurt op een botter en dus voor bpaalde tijdvakken verbonden is onderwindt inzo
Toch mag en kan niet worden gezegd dat: er op ons eiland een geest van verzet tegen het vervullen van den dienstplicht wordt gevonden.
Daar is gelukkig geen spoor van te ontdekken dank zij de eerbied voor de Overheid en den invloed van het gezag t welk het Woord van God hier
Al zijn de bedoelde lasten inzonderheid voor onze visschers zwaar ze worden geduldig gedragen omdat ze door de Overheid zijn opgelegd en ook
Dit neemt evenwel niet weg dat er met groote belangstelling nota wordt genomen van elke nieuwe regeling van denzyxwvutsrqponmlkjhgfedcbaZYXW
ZIJ d18 een onteerend vonnis hebben En daarom dacht het ons niet onge- rondergaan.) past in ons blad mededeeling te doen .1 Na afrek van de
Deze moeten nu volgens de nieuwe kort geleden zijn aangebracht " wet eerst allen gekeurd worden wat Zeer belangwekkend is de opmerking een mo
21.000 zullen worden afgekeurd De zaak is aldus; zoodat er. dus voor den dienst circa Jaarlijks vallen er circa 23.000 jonge 23.000 over blij
Volgens de nieuwe mannen in de termen om; wat hun wet moeten dezen nu loten maar aanleeftijd betreft bij het leger te worden gezien. het jaar
Volgens de nu vervallen zooals bekend juist ook 23.000 man zal militietwet moesten van deze circa bedragen kan er wel geloot worden 53.000 ma
Vervolgens werden deze 17.500 dat het loten geen zin meer h ett.
Die man gekeurd en voor diegenen die we- nu goedgekeurd wordt weet dus dat gens lichaangebreken enz. afvielen hij dienen moet en de verderfel
Dat verschillig of zij sterk en gezond waren is een feit van betekenis waarvan de of niet.
De keuring geschiedde met gevolgen slechts gunstig voor onze zachte hand tengevolge waarvan steeds volkskracht kunnen zijn . / een met aanzie
Volgens de nieuwe militietwet zullen nu om te beginnen de zoogenaamde kostwinners in vredestdijd vrij van dienst zijn (zooals bekend moesten zi
```

Controleer dus altijd steekproefgewijs de door pdf2zcbcs.exe aangemaakte OCR !!

2. Invulling van velden van eventueel aan te maken databaserecords (UPDATES.TXT)

In het *tweede gedeelte* (beginnend met 00, 01, etc) kunnen al vast (default) waarden van de velden worden opgegeven voor de betreffende ZCBS-beeldbank.

De velden 00 en 01 zijn natuurlijk ZCBS-*instellingsafhankelijk*.

Indien bestandsnaam van de afbeelding *niet gelijk is* aan het recordnummer (\$IMAGE_LOC is vermeld in de config file), dan dient tevens opgegeven te worden:

```
02 00100 15      ## 00100 is eerste rec.nr.; 15 is waarde van $IMAGE_LOC
```

Alleen als binnen pdf2zcbcs.ini (minimaal) de velden 00 en 01 zijn opgegeven, wordt er het bestand output/updates.txt aangemaakt met eventueel de opgegeven aanvullende velden.



3. Aanpassing databasevelden afhankelijk van bepaalde pdf2zcb's variabelen (INSERT_DB)

In sommige gevallen kan het handig zijn om de database velden te vullen *afhankelijk* van bepaalde waarden binnen het pdf2zcbcs programma. Binnen pdf2zcbcs wordt dit geregeld via een eigen INSERT DB.³

De variabelen binnen pdf2zcbis die uitgelezen kunnen worden zijn:

`$file` : de output PDF bestandsnaam (namen); deze bevat veelal *jaar, uitgavenummer en/of paginanummer(s)*

\$str\$: de volledige OCR tekst; de lengte hiervan geeft (pagina) informatie over de *verhouding tekst/afbeelding*

De databasevelden zijn binnen de INSERT van het programma bekend onder de naam %IN{"veldnummer"}, waarbij veldnummer loopt van 02 t/m 31.

Zie bijvoorbeeld de `$INSERT_DB` binnen het bestand `pdf2zcbis.ini` in onderstaande voorbeeld.

De \$INSERT_DB wordt uitgevoerd vlak voordat elke keer een databaserecord naar updates.txt wordt weggeschreven.

```
#####
##
## pdf2zcbcs.ini bestand
## 24-12-2021
## Tijdschrift: Zijper Historie Bladen
## Historische Vereniging "De Zijpe" (#12)
##
## Let op: eerst de PDF door pdf24 halen (optie pag extraheren/uithalen)!!!!
##
#####
SP Ja ## PDF splitsen in losse pagina's?
OP 202104 ## Output PDF [AANPASSEN]
LP 2 ## Loze Pagina's
PN 2 3 4-6 7-12 13-21 22-23 ## Pagina Nummers [AANPASSEN]
TJ Ja ## verwerken naar Txt en Jpg
PS Nee ## Presentatie Slide ?
#####
00 HVZ ## afk. instelling (zie config)
01 12 ## inst. nummer
22 Tijdschrift ## veld-22
23 Historische Vereniging "De Zijpe" ## veld-23
10 Gepubliceerd ## veld-10
#####
$INSERT_DB = <<'EOR'; ## bestandsnaam b.v.: 2021041012
$blz1 = substr($file,6,2); ## skip eerste 6 en pak de volgende 2
$blz2 = substr($file,8,2); ## skip eerste 8 en pak de volgende 2
$blz1 =~ s|^0||; ## verwijder een eventuele voorloop 0
$blz2 =~ s|^0||;
if ($blz1 eq $blz2) { ## begin pagina hetzelfde als eind pagina?
    $IN{"03"} = $blz1; ## veld-03 = paginanummer artikel
} else {
    $IN{"03"} = "$blz1-$blz2";
}
$jaar = substr ($file,0,4); ## pak de eerste 4 cijfers (= jaar)
$uitgave = substr ($file,4,2); ## skip eerste 4 en pak de volgende 2
$IN{"24"} = "$jaar-$uitgave"; ## veld uitgavenummer
EOR
#####
```

Gebruik bij de beeldbank: www.dezijpe.nl/cgi-bin/zhb.pl

³ INSERT's kunnen worden gebruikt binnen ZCBS via de config file. Daarnaast kent ook het programma `images.exe` een eigen INSERT.

De volgende pdf2exe.ini is gebruikt bij de beeldbank: www.zaadenkruid.nl/cgi-bin/weinmann.pl

```
#####  
##  
## pdf2zcbs .ini bestand  
## 04-06-2021  
## Weinmann boeken  
## Museum Saet & Cruyt (#15)  
##  
#####  
OCR -raw  
#####  
00 SC ## afk. instelling (zie config)  
01 15 ## inst. nummer  
  
03 0 ## bandnummer  
21 7971 ## op internet  
#####  
$INSERT_DB = <<'EOR';  
$tmp = length($str); ## de lengte van de gehele OCR-tekst  
$IN{"04"} = "Blanco"; ## de default waarde  
$IN{"04"} = "Afbeelding" if ($tmp > 10); ## minimaal een afbeelding bij > 10 tekens  
$IN{"04"} = "Tekst" if ($tmp > 500); ## zeker een tekstpagina bij > 500 tekens  
print ("==lengte OCR: $tmp --> $IN{\\"04\\"}==\\n"); ## output regel ter controle  
EOR  
#####
```

Bij deze beeldbank zijn de *afzonderlijke pagina's* van de Weinmann boeken als *aparte records* in de database opgenomen. De pagina's bevatten i.h.a. alleen tekst dan wel alleen een afbeelding (of een blanco pagina achter de afbeelding).

Afhankelijk van de *lengte van de OCR-string* (de variabele \$str) wordt reeds automatisch een voorlopige keuze hierin gemaakt tussen type pagina: tekst en afbeelding.



In het pdf2zcbs.ini voorbeeld van de Weinmann boeken is tevens de volgende parameter opgenomen:

OCR -raw

Deze parameterinstelling geeft in dit specifieke geval een *beter resultaat* bij het extraheren van de OCR-tekst uit het PDF-bestand.

Voorbeelden van pdf2exe.ini bestanden zijn als bijlage (.zip bestand) opgenomen in de ZCBS-documentenbank, documentnummer #50:

ZCBS Documentatie

Bijlage J:

Handleiding PDF-2-ZCBS

ZCBS-hulpprogramma
om

PDF-bestanden te converteren

[Resize via rechteronderhoek \(niet in Internet Explorer\) **of** open deze PDF beeldvullend in apart window](#)

Documentnummer : 050

Titel : Handleiding J: pdf2zcbs.exe

Auteur(s) : Nes, G.J.H. van (Gerard)

Datum laatste versie : 07-08-2021 (Opm.: diverse aanpassingen t.o.v. versie 1.0 (van 03-03-2021) en versie 1.1 (van 15-04-2021))

Bijlage(n):


- Voorbeelden van pdf2exe.ini bestanden

Wilt u reageren op bovenstaand document?

Wij vernemen dat zeer graag van u via het [reactieformulier](#)

9. Upload bestanden naar de webserver

De *output* van het programma `pdf2zcbcs.exe` (welke is te vinden in de map `output`), moet nog wel op de webserver geplaatst worden in de map `/public_html/[document]/`, waarbij `document` de naam van de toepassing is.



Dit proces is niet opgenomen binnen het programma `pdf2zcbcs.exe` (i.t.t. bij het programma `images.exe`).

Het *eventueel* aangemaakte bestand `updates.txt` moet geplaatst worden in de map `/cgi-bin/[beeldbank]/`. Echter daartoe dient eerst een MERGE uitgevoerd te worden om er voor te zorgen dat een reeds aanwezige `updatedatabase` `updates.txt` wordt opgenomen in de masterdatabase en een reeds aanwezige `updates.txt` niet overschreven kan worden op de webserver.

10. CONFIG instellingen

Voor een goed doorzoekbare beeldbank met de bovenstaande aangemaakte PDF-bestanden dienen in de config file van de beeldbanktoepassing wel de volgende 2 variabelen te zijn opgenomen, bijvoorbeeld:

```
- $PDF_VIEWER = ...;
- $OCR_MAP = "documenten/ocr"; ## locatie OCR-bestanden op de webserver
```

De **eerst genoemde variabele** kan de volgende waarden bevatten:

```
$PDF_VIEWER = 1; ## PDF-bestanden staan in de map large
$PDF_VIEWER = [getal 3-30]; ## (eventueel verschillende) locatie PDF-
                             ## bestanden staan in opgegeven veld(nummer)
$PDF_VIEWER = [path naar PDF-map]; ## PDF-bestanden staan in opgegeven map
```

Veelal zal worden opgegeven zoiets als:

```
$PDF_VIEWER = "/documenten/pdf"; ## bestanden in webserver map /documenten/pdf
```

De **tweede genoemde variabele** kan 2 vormen aannemen:

```
$OCR_MAP = "documenten/ocr"; ## zoek OCR-tekst in opgegeven map
```

of:

```
$OCR_MAP = "documenten/ocr/"; ## idem
```

In het laatste geval wordt op de homepage het volgende blokje keuzetekst *niet* getoond:

6. Zoeken in OCR-tekst publicaties: ☒ Ja ☐ Neen

Wil men bijvoorbeeld bij een tijdschriftenbeeldbank alleen tijdschriften (in map `/abc`) ouder dan 4 jaar aop internet plaatsen, dan kan daarvoor bijvoorbeeld de volgende INSERT in de config file worden opgenomen:

```
$INSERT .= <<'EOR';
$PDF_VIEWER = "";
if ($PRIVATE =~ /1|2|3|4/) { ## interne bezoekers mogen alle tijdschriften bekijken
    $PDF_VIEWER = "/abc/pdf";
} elsif ($ident =~ /\d{4}/) { ## recordnummer waarbij eerste 4 cijfers het jaartal is
    $tmp = $1;
    $PDF_VIEWER = "/abc/pdf" if ($YEAR-$tmp > 4); ## alleen PDF indien artikel > 4 jaar oud
}
EOR
```

De variabele `$YEAR` is het huidige jaar.

11. Verdere opmerkingen

- 
1. **Controleer regelmatig de geëxtraheerde OCR-tekst!**
Afhankelijk van de manier waarop de PDF aanvankelijk is aangemaakt, kan de kwaliteit van de OCR verschillen van zeer goed tot matig/slecht.
Gelukkig zijn er meerdere mogelijkheden om toch tot een goed eindresultaat te komen.
 2. Er kunnen doorzoekbare PDF documenten zijn (dus met OCR aangemaakt) waaruit het programma `pdf2zcbcs.exe` niet de OCR kan extraheren.
Probeer in dat geval een conversie met de eerder genoemde software PDF24.
 3. Soms komt het bij bepaalde doorzoekbare PDF documenten ook voor dat zowel lege OCR als lege afbeeldingen worden aangemaakt.
Probeer ook in dat geval een conversie met met de eerder genoemde software PDF24.
 4. Dikwijls worden PDF documenten *gecomprimeerd* waardoor ze door `pdf2zcbcs.exe` niet goed verwerkt kunnen worden.
Ook hier geldt dat conversie met PDF24 veelal de oplossing is (PDF24 levert als output niet-gecomprimeerde PDF's).
 5. Ook de regel:
OCR -raw
in het `pdf2zcbcs.ini` bestand, kan tot een goed resultaat leiden. Dit afhankelijk hoe de oorspronkelijke PDF is aangemaakt.
 6. De kwaliteit van de OCR in de PDF is vanzelfsprekend afhankelijk van een al dan niet goed uitgevoerde scan en/of van een al dan niet duidelijk document (grootte karakters, oudheid document, gebruik van font, gedrukte of getypte tekst, etc.). De kwaliteit is terug te vinden in het uiteindelijke aangemaakte OCR-bestand van het programma `pdf2zcbcs.exe`.
 7. Bij *krantenartikelen* wordt, afhankelijk van de opmaak en ouderdom, de tekst niet altijd goed geëxtraheerd (zinnen van verschillende kolommen kunnen door elkaar lopen).
 8. Daarnaast is de OCR-extractie uit een PDF ook afhankelijk hoe de tekst in de PDF is gerangschikt (in één of meerdere kolommen, veel afbeeldingen tussen de tekst met onderschriften, de OCR van de afbeeldingen in het document, alsmede ook hoe de OCR-tekst in de PDF is opgeslagen).
 9. De OCR-tekst is ook afhankelijk van welk programma de OCR-tekst uit de PDF extraheert. Bij `pdf2zcbcs.exe` is dat de utility `pdftotext.exe`.
Een ander alternatief goed (gratis) programma is bijvoorbeeld *PDFMate PDF Converter Free Version* (www.pdfmate.com ; gebruik Custom Installation!!).
 10. Een OCR-zin hoort binnen `pdf2zcbcs.exe` te eindigen met *een punt*. Wanneer de punt ontbreekt zal de zin dus met een volgende zin gekoppeld zijn waardoor niet de zin een eigen regel krijgt.
 11. Bij de OCR-omzetting wordt door `pdf2zcbcs.exe` wel rekening gehouden met *afbreekstreepjes* in de oorspronkelijke PDF-OCR !
 12. De volgende regels in het input bestand worden verwijderd:
 - regels bestaande uit alleen getallen
 - regels met minder dan 3 letters
 - exact gelijke regels
 13. De door `pdf2zcbcs.exe` gesplitste PDF-artikelen bevatten geen *PDF Xref tabellen*.
Voor verdere verwerking van `pdf2zcbcs.exe` is dat echter geen probleem. De Acrobat Reader maakt bij het inlezen van een PDF automatisch deze tabellen aan. Dat betekent dus dat bij het vervolgens opslaan van de in de Acrobat Reader getoonde PDF, het opgeslagen bestand groter is!
 14. Bij elke doorloop van het programma wordt de map `output` geleegd. Alle bestanden worden verwijderd om de uitvoer zo zuiver mogelijk te houden.
Wanneer daar aanleiding voor is, verdient het dan ook aanbeveling om na elke doorgang de map `output` te hernoemen door het bijvoorbeeld een volgnummer te geven zodat deze uitvoer niet later door het programma kan worden gewist.
- 
- 

12. Tot slot

- Het programma `pdf2zcbs.exe` is volledig geschreven in de scripttaal Perl en daarna omgezet met de `perl2exe.exe` conversie tool (zie: www.indigostar.com) in een executable.
- Het programma maakt gebruik van de Perl module <https://metacpan.org/pod/PDF::Extract> en van de xpdfreader.com onderdelen: `pdftotext.exe` en `pdftopng.exe`, beide versie 4.03 (28-01-2021). Deze 2 bestanden zijn te vinden in de map `/bin`.
- Het programma `pdf2zcbs.exe` kent een **debug mode** aan te roepen via: `pdf2zcbs.exe 1`
Het genereert dan een extra output file `output/debug.lst` met de *onbewerkte* OCR-output (*dus niet gesplitst in hele zinnen per regel*).
- Zowel de **source code** van het programma `pdf2zcbs.exe` als het **bijbehorende tekstuele flowdiagram**, zijn te vinden in de ZCBS-documentenbank als bijlage van record #50 (*deze bijlagen zijn alleen toegankelijk voor bestuur en leden van de Perl-werkgroep*).

Bijlage(n):

- [Overzicht/programmafow/commentaarregels van het Perl-script : pdf2zcbs.pl](#)
- [Source code van het programma : pdf2zcbs.exe](#)
- [Voorbeelden van pdf2exe.ini bestanden](#) *

Wilt u reageren op bovenstaand document?
Wij vernemen dat zeer graag van u via het

- De belangrijkste aanpassingen in het programma `pdf2zcbs.exe`, sinds de introductie *begin 2021*, waren:

```
1.00 (03-03-2021) : --- : eerste versie
1.10 (01-04-2021) : add : pdf2zcbs.ini file voor aanmaak database + diverse kleine aanpassingen
1.10 (01-04-2021) : onh : pdf's altijd plaatsen in dezelfde map als pdf2zcbs (opm. Cor Spruit)
1.10 (12-04-2021) : onh : alle output naar de map output
1.11 (22-05-2021) : onh : tekstuele aanpassing; delete ook als PC-map spaties in naam bevat
1.11 (22-05-2021) : onh : aanpassingen in OCR_ZINNEN (n.a.v. opmerking #090 Ton van Soest)
1.12 (04-06-2021) : add : $INSERT_DB toegevoegd, te plaatsen in pdf2zcbs.ini
                        (toegepast bij #015: Weinmann boeken)
1.13 (10-06-2021) : add : INI-file : toegevoegd de pdftotxt.exe optie: OCR -raw
                        (toegepast bij #015: Weinmann boeken)
1.13 (17-06-2021) : onh : DUBBELE regels verwijderd in OCR-output; veroorzaakt door -raw parameter
                        (#115: Heraut)
1.14 (23-06-2021) : bug : LOC_IMAGE: 02 = 1e recordnummer $LOC_IMAGE : bij recordnummer ongelijk
                        aan bestandsnaam (documenten #086: Urk)
1.14 (30-06-2021) : onh : INI-file : \n op eind verwijderd in alle regels
1.15 (02-08-2021) : bug : LP parameter (dus ook $DEL) kan ook negatief zijn bij doornummeren van
                        opeenvolgende tijdschriftuitgaven (#102: Drijehornick)
1.15 (07-08-2021) : add : DEBUG-mode : ook output van foutmeldingen van pdftotext en pdftopng.
1.15 (05-10-2021) : onh : AFKORTINGEN/etc
1.16 (07-11-2021) : onh : ANSI output geforceerd
```